Моделирование эквивалентного цифрового двойника Overlay для облачных DC на основе дедупликации логических инстансов

Чи Цинюань 31 Октября 2026

Аннотация

С быстрым развитием интенционально-управляемых сетей (IBN) на основе больших языковых моделей (LLM) в облачных центрах обработки данных (ЦОД), технологии цифровых двойников стали важнейшей «песочницей» для верификации сетевых интентов и предотвращения конфигурационных галлюцинаций LLM. Однако традиционное полномасштабное моделирование 1:1 на основе физической топологии Underlay сталкивается с серьезным взрывным ростом вычислительных затрат и задержками симуляции. Это обусловлено массовым дублированием физических инстансов, вызванным архитектурой распределенных шлюзов (EVPN-VXLAN), что делает невозможным обеспечение верификации в замкнувом цикле на секундном уровне.

В данной работе предлагается легковесный метод моделирования цифровых двойников, ориентированный на логический уровень Overlay. Используя свойство прозрачности протокола VXLAN для сервисов верхнего уровня, данный подход абстрагирует детали физической инфраструктуры и осуществляет логическую дедупликацию инстансов виртуальной маршрутизации и форвардинга (VRF) и мостовых доменов (BD), распределенных по множеству физических коммутаторов Leaf. В работе построена математическая модель вычислительных затрат при эквивалентных ограничениях верификации.

Теоретически доказано, что предложенный метод снижает сложность пространства состояний цифрового двойника с $O(N^2+T\cdot N)$ до $O(T)$, где N — масштаб физической сети коммутаторов, а T — общий масштаб арендаторов сетей. Многомерное моделирование методом Монте-Карло показало, что при обеспечении полной эквивалентности верификации сетевой связности и изолированности, предложенный метод обеспечивает сжатие пространства ресурсов до 61.78 раза в сценарии крупномасштабной сети, включающей 100 коммутаторов Leaf и 300 арендаторов. При этом пространство состояний двойника демонстрирует абсолютный иммунитет к расширению физических узлов со свойством константы класса $O(1)$. Данный легковесный базис значительно повышает эффективность верификации цифровых двойников, закладывая надежную основу для создания высокоскоростных платформ защиты от галлюцинаций в будущих сетях IBN на базе больших языковых моделей и обеспечивая их автономную работу в режиме реального времени.

Ключевые слова: цифровой двойник; интенционально-управляемая сеть (IBN); облачный центр обработки данных; абстракция Overlay; дедупликация логических инстансов; большие языковые модели

I. Введение

В последние годы глубокая интеграция интенционально-управляемых сетей (IBN) и больших языковых моделей (LLM) стала ключевым направлением развития интеллектуальной эксплуатации сетей (NetOps) следующего поколения. Благодаря своим мощным возможностям понимания естественного языка LLM способны напрямую преобразовывать абстрактные бизнес-интенты пользователей в сложные конфигурационные скрипты для сетевого оборудования. Однако галлюцинации, присущие генеративным большим моделям, несут в себе высокие риски, так как генерируемые ими инструкции могут содержать логические конфликты, дублирование конфигураций или нарушения изолированности. Непосредственное развертывание таких некорректных команд в реальной сети может привести к непредсказуемым сетевым сбоям. Следовательно, перед фактической отправкой конфигураций в продуктивную среду необходимо провести их упреждающую верификацию на соответствие политикам безопасности в высокоточной симуляционной среде цифрового двойника.

В сценариях современных облачных центров обработки данных (ЦОД) сетевая архитектура повсеместно использует топологию Spine-Leaf на основе распределенных шлюзов Anycast (таких как EVPN-VXLAN). Для обеспечения беспрепятственной миграции виртуальных машин (VM) в пределах всего ЦОД и поддержки больших L2-сетей инстансы виртуального частного облака (VPC), домены виртуальной маршрутизации и форвардинга (VRF) и мостовые домены (BD) одного и того же арендатора развертываются в распределенном виде на множестве физических коммутаторов Leaf (VTEP). В традиционном полномасштабном моделировании цифрового двойника 1:1 на физическом уровне Underlay для проверки корректности конфигурации система вынуждена запускать соответствующий образ сетевой операционной системы (NOS) или контейнерный процесс для каждого физического устройства, а также полностью симулировать полносвязную (Full-Mesh) сеть физических туннелей VXLAN во всем масштабе ЦОД.

Такой традиционный подход к полному моделированию сталкивается с критической проблемой взрывного размножения физических инстансов. Рассмотрим конкретный пример. Предположим, что в облачном ЦОД один типичный арендатор (VPC) имеет 1 логический VRF и 2 логических мостовых домена (BD). В домене BD1 размещены 4 виртуальные машины, а в BD2 — 3 виртуальные машины. Из-за случайного характера механизмов облачного планирования эти 7 виртуальных машин оказываются распределены ровно по 7 различным физическим коммутаторам Leaf. Если использовать полное физическое моделирование 1:1, система будет обязана запустить и поддерживать на всех 7 виртуальных коммутаторах по одной идентичной копии процесса VRF, инстанса BD и конфигурации трехслойного интерфейса IRB (VBDIF). Когда сеть включает T арендаторов и виртуальные машины каждого арендатора сильно рассредоточены, общее количество физических конфигурационных инстансов в песочнице двойника будет расти лавинообразно как произведение числа арендаторов на число устройств. Это приводит к тому, что построение цифрового двойника требует колоссальных вычислительных ресурсов оборудования, а цикл верификации растягивается до минут или даже часов, что полностью лишает цифровой двойник ценности как инструмента обеспечения безопасности IBN на секундном уровне.

Для решения данной проблемы в настоящей работе предлагается метод легковесного моделирования цифровых двойников, ориентированный на логический уровень Overlay. Основной вклад данной работы заключается в следующем. Во-первых, предложена легковесная архитектура цифрового двойника Overlay для облачных ЦОД на основе логической дедупликации инстансов, которая полностью устраняет зависимость от физического уровня Underlay и разрывает связь между вычислительными затратами симуляции и масштабом физических

коммутаторов. Во-вторых, построена строгая математическая модель пространственных затрат ресурсов при эквивалентных ограничениях верификации, доказывающая снижение сложности с $\mathcal{O}(\mathrm{N}^2 + \mathrm{T} \cdot \mathrm{N})$ до $\mathcal{O}(\mathrm{T})$. В-третьих, посредством многомерного случайного моделирования методом Монте-Карло количественно подтверждено, что предложенный метод обеспечивает сжатие пространства состояний ресурсов более чем в сто раз в условиях крупномасштабных сетей, демонстрируя полную независимость от расширения физической топологии.

II. Отображение архитектуры и бизнес-эквивалентность

A. Архитектура легкого отображения Overlay и логика дедупликации

Принцип моделирования двойника, предлагаемый в данной работе, формулируется как «абстрагирование нижнего уровня, дедупликация верхнего уровня, бизнес-эквивалентность». Этот метод переворачивает традиционный подход обратного моделирования и напрямую конструирует логический двойник на основе высокоуровневых бизнес-сущностей VPC, VRF и BD как базовых элементов первого класса. Правила отображения определены следующим образом:

1.VPC--Логический VRF: Виртуальное частное облако арендатора абстрагируется в виде единого в рамках всей сети логического узла трехслойной зоны маршрутизации после дедупликации.

2.Подсеть внутри VPC--Логический BD: Отображается в виде дедуплицированного логического узла двухуровневого широковещательного мостового домена (Bridge Domain).

3.Виртуальная машина--Конечный узел: Конечная виртуальная машина освобождается от привязки к физическому хосту размещения и напрямую подключается к соответствующему логическому узлу BD.

В легковесном цифровом двойнике Overlay полностью удаляются сущности физических коммутаторов Leaf и полносвязные физические туннели VXLAN между ними. Метаданные отображения, указывающие, на каких именно физических шлюзах VTEP распределены конкретные VRF/BD в реальной сети, поддерживаются на уровне таблиц в оперативной памяти SDN-контроллера и не разворачиваются в цифровом двойнике в качестве независимо работающих объектов симуляции.

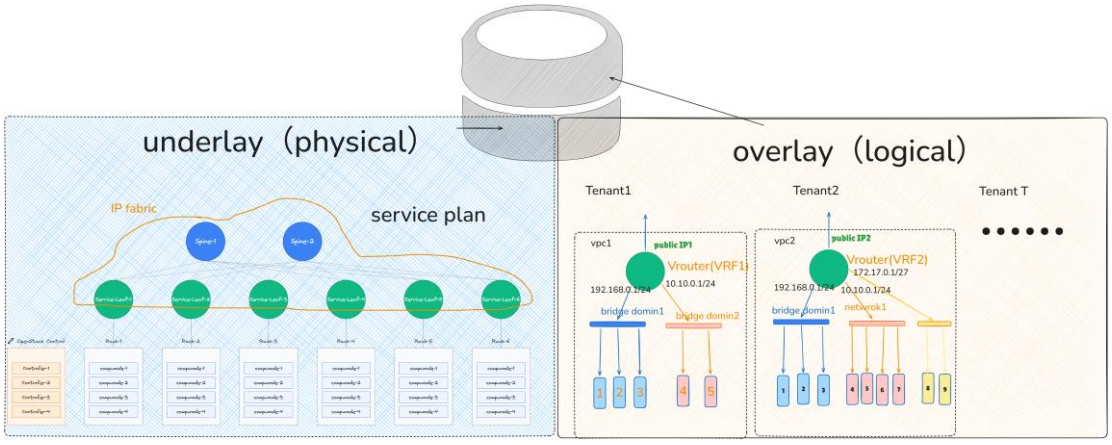


Рис. 1. Сравнительная схема архитектуры полномасштабного физического моделирования Underlay 1:1 и логического дедуплицированного моделирования Overlay в облачном ЦОД.

Б. Строгое определение бизнес-эквивалентности

Для того чтобы легковесная модель после удаления физических деталей сохраняла способность точно перехватывать конфигурационные галлюцинации больших моделей, вводится строгое математическое определение «бизнес-эквивалентности». Пусть $\mathcal{R}$ — множество задач верификации сетевой безопасности и интентов, сгенерированных LLM (включая проверку жесткой изоляции между VPC, связности внутри подсетей, межсегментной маршрутной достижимости, соответствия политик ACL и др.). Пусть $\mathrm{M_u}$ обозначает традиционную модель полного физического двойника, а $\mathrm{f_u(r)}, \mathrm{r} \in \mathcal{R}$ — соответствующую функцию принятия решений. Пусть $\mathrm{M_o}$ обозначает предлагаемую модель логического дедуплицированного двойника, а $\mathrm{f_o(r)}$ — её функцию принятия решений. Модели признаются бизнес-эквивалентными тогда и только тогда, когда результаты их решений полностью совпадают для любых задач из множества:

$$\mathrm{Equiv}(M_u, M_o) \Leftrightarrow \forall r \in \mathcal{R}: f_u(r) = f_o(r)$$

В. Обоснование правомерности упрощения Underlay

Ключевым предварительным допущением данной модели является игнорирование заторов на линках Underlay и детальных механизмов инкапсуляции нижнего уровня. Данное допущение опирается на особенности функционирования современных облачных ЦОД в промышленности. Сети ЦОД повсеместно используют высокоизбыточные двух- или трехъярусные топологии Clos с балансировкой нагрузки ECMP для равномерного распределения трафика. Данные измерений в реальных крупных ЦОД показывают, что средняя утилизация физических каналов Underlay стабильно поддерживается на низком безопасном уровне около 20%-30%. Поскольку сама инкапсуляция VXLAN полностью прозрачна для потоков данных бизнес-сервисов верхнего уровня, флуктуации физических маршрутов не меняют логическую корректность конфигураций верхнего уровня (таких как неверно назначенные IP-адреса или пропущенные правила ACL). Таким образом, абстрагирование от деталей Underlay не приводит к падению точности верификации связности и изолированности сервисов.

III. Математическая модель вычислительных затрат симуляции (Mathematical Overhead Model)

Для строгого теоретического доказательства причин экономии ресурсов в данном разделе строится модель пространства состояний асимптотической сложности для обоих вариантов цифровых двойников. Предположим, что в сети имеется N физических коммутаторов Leaf (VTEP), а общее число арендаторов составляет T. Для i-го арендатора количество запланированных бизнес-логикой мостовых доменов составляет $\mathrm{b_i}$.

А. Затраты традиционной полномасштабной модели Underlay 1:1 ($\mathbf{M_u}$)

При полном физическом моделировании система обязана создавать копии каждого инстанса шлюза на всех физических коммутаторах Leaf, где они фактически размещены. В худшем случае

полного рассредоточения виртуальных машин пусть $S_{bd}(i,j)$ обозначает множество физических коммутаторов Leaf, на которых распределен j-й домен BD i-го арендатора, а $S_{vrf}(i)$ — множество коммутаторов для соответствующего трехмерного VRF. Тогда суммарное пространство состояний S_u (общее число запущенных сущностей и записей в таблицах) для полной физической модели M_u определяется как:

$$S_u = \sum_{i=1}^{T} \left(\sum_{j=1}^{b_i} |S_{bd}(i,j)| \right) + \sum_{i=1}^{T} |S_{vrf}(i)| + N \cdot C_{leaf} + \frac{N(N-1)}{2} \cdot C_{tun}$$

где C_{leaf} — постоянные затраты базовой операционной системы NOS одного физического коммутатора, а C_{tun} — постоянные затраты на поддержание состояния одного физического Full-Mesh туннеля на плоскости данных цифрового двойника. С увеличением физического масштаба сети N и количества арендаторов T мощность множества распределения $|S_{bd}|$ стремится к N, из-за чего число копий конфигураций в первых двух членах растет со сложностью $\mathcal{O}(T \cdot N)$. Одновременно с этим число туннелей из-за полносвязной топологии демонстрирует жесткий квадратичный взрыв $\mathcal{O}(N^2)$. Таким образом, верхняя граница сложности пространства состояний полной модели M_u составляет:

$$S_u = \mathcal{O}(N^2 + T \cdot N)$$

Б. Затраты предлагаемой модели логической дедупликации Overlay (M_o)

В модели логического двойника Overlay полностью исключаются все физические узлы и полносвязные туннели Underlay, а идентичные конфигурации на разных физических коммутаторах объединяются и дедуплицируются. Независимо от географической распределенности BD или VRF в реальной сети, в песочнице двойника они инициализируются ровно 1 раз. Общие затраты пространства состояний S_o выражаются формулой:

$$S_o = \sum_{i=1}^{T} (b_i + 1) \cdot C_{obj} + E_{logic} \cdot C_{link}$$

где C_{obj} — удельные постоянные затраты на один чистый логический бизнес-объект (VRF или BD) на дедуплицированной платформе; E_{logic} — общее количество базовых логических связей топологии между виртуальными машинами и логическими BD внутри арендаторов; C_{link} — постоянные затраты на поддержку одной логической связи.

Поскольку в реальных ЦОД количество подсетей b_i и число виртуальных машин одного арендатора определяются исключительно его собственной бизнес-архитектурой, они представляют собой конечные малые константы (обычно от 2 до 6), не зависящие от масштаба физического оборудования N. Следовательно, средние логические затраты на одного арендатора можно объединить в константу K, что упрощает формулу до вида:

$$S_o = \sum_{i=1}^{T} K = K \cdot T$$

Это теоретически доказывает, что сложность пространства состояний модели логической дедупликации $\mathrm{M_o}$ демонстрирует строгую линейную зависимость от масштаба арендаторов и полностью изолирована от количества физических коммутаторов N:

$\mathrm{S_o} = \mathcal{O}(\mathrm{T})$

B. Вывод теоретического коэффициента сжатия

Для наглядной оценки эффективности сжатия пространства состояний определим теоретический коэффициент сжатия (Compression Ratio, CR) как отношение затрат традиционной модели к предлагаемой легковесной модели:

$$CR = \frac{S_u}{S_o} = \frac{\sum_{i=1}^{T} (\sum_{j=1}^{b_i} |S_{\mathrm{bd}}(i,j)|) + \sum_{i=1}^{T} |S_{\mathrm{vrf}}(i)| + N \cdot C_{\mathrm{leaf}} + \frac{N(N-1)}{2} \cdot C_{\mathrm{tun}}}{\sum_{i=1}^{T} (b_i + 1) \cdot C_{\mathrm{obj}} + E_{\mathrm{logic}} \cdot C_{\mathrm{link}}}$$

Когда масштаб физической сети N относительно мал, а количество тенантов T велико, логические связи в знаменателе и физические константы в числителе нивелируются общим ростом масштаба. Сокращенная формула для оценки эффективности сжатия инстансов Anycast-шлюзов принимает вид:

$$CR \approx \frac{\sum_{i=1}^{T} (\sum_{j=1}^{b_i} |S_{\mathrm{bd}}(i,j)| + |S_{\mathrm{vrf}}(i)|)}{\sum_{i=1}^{T} (b_i + 1) \cdot C_{\mathrm{obj}}}$$

Эта формула математически раскрывает фундаментальную логику экономии ресурсов: числитель представляет собой сумму бизнес-инстансов, вынужденно продублированных на физических устройствах из-за распределенной архитектуры шлюзов, а знаменатель отражает чистые уникальные бизнес-объекты после дедупликации. Независимо от изменения T, данный коэффициент CR стабилизируется в постоянном диапазоне, определяемом средней степенью рассеяния виртуальных машин по коммутаторам ($|\mathrm{S_{bd}}|$). Однако при масштабном горизонтальном увеличении физической сети N член квадратичной сложности $\frac{1}{2}\mathrm{N}^2 \cdot \mathrm{C_{tun}}$ в числителе начинает доминировать, вызывая скачкообразный рост CR на порядки.

IV. Имитационное моделирование и анализ результатов

A. Настройки симуляции и ключевые показатели

Для количественного сопоставления тенденций развития обеих моделей была разработана система случайного моделирования методом Монте-Карло на основе больших выборок. Скрипт симуляции и алгоритмические фреймворки вынесены в открытый репозиторий в качестве приложения к работе. Базовые параметры симуляции: диапазон масштаба физической сети задан как $\mathrm{N} \in [10{,}100]$ коммутаторов Leaf (что охватывает путь от архитектуры одного POD до масштабов крупнейших кампусных ЦОД); масштаб арендаторов T сканируется в диапазоне от 10 до 400. Количество логических BD для каждого арендатора подчиняется случайному распределению $\mathrm{b_i} \sim \mathrm{U}(2{,}6)$ в соответствии с типовой трехъярусной ИТ-архитектурой. Размещение виртуальных машин моделируется как высокохаотичное, при этом виртуальные машины тенанта случайно распределяются по $20\% - 60\%$ физических коммутаторов Leaf.

В результате выполнения многомерных экспериментов были интегрированы данные для различных сечений изменяющихся независимых переменных, а ключевые точки зафиксированы в результирующей таблице и на графиках динамических кривых, представленных на Рисунке 2.

ТАБЛИЦА I: Экспериментальные кросс-секционные данные при различных масштабах физической сети (N)

Leaf (N)	Su (T=50)	So (T=50)	Su (T=300)	So (T=300)	CR (T=300)
10	1879	348	9415	2139	4.40
20	4860	328	22122	2127	10.40
30	7195	350	33095	2087	15.86
40	10964	360	45208	2078	21.76
50	15295	346	58747	2113	27.80
60	20286	368	72156	2075	34.77
70	25063	342	84535	2093	40.39
80	30264	347	98584	2078	47.44
90	35991	348	111693	2070	53.96
100	43110	365	129560	2097	61.78

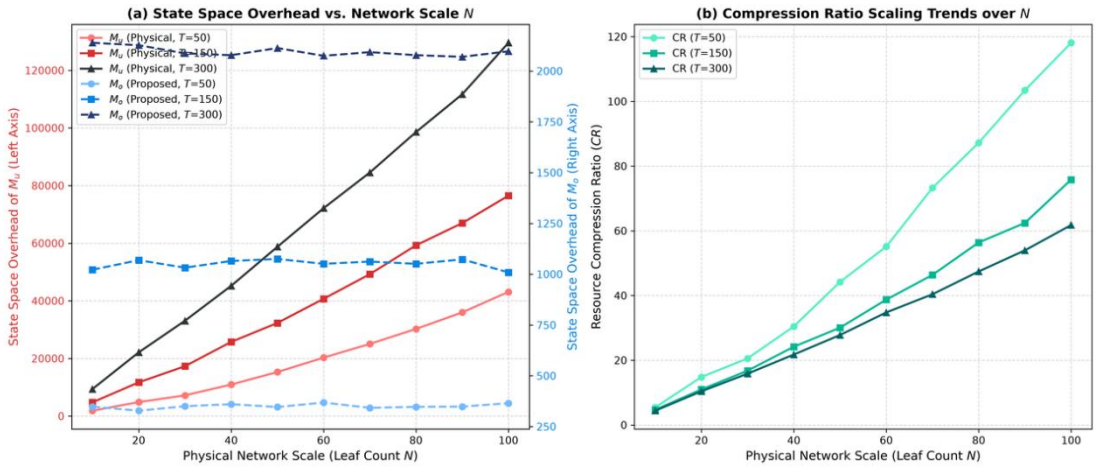


Рис. 2. Сравнительные кривые пространства состояний ресурсов и тенденции изменения коэффициента сжатия при многомерном изменении переменных (с использованием двойной оси Y).

При масштабе $N = 10$ коммутаторов Leaf: затраты физической модели составляют 1 879; затраты предлагаемой логической модели Overlay — 348 (коэффициент сжатия 4.40×).

При масштабе $N = 40$ коммутаторов Leaf: затраты физической модели составляют 10 964; затраты предлагаемой логической модели Overlay — 360 (коэффициент сжатия 21.76×).

При масштабе $N = 70$ коммутаторов Leaf: затраты физической модели составляют 25 063; затраты предлагаемой логической модели Overlay — 342 (коэффициент сжатия 40.39×).

При масштабе $\mathrm{N} = 100$ коммутаторов Leaf (крупный кластер): затраты физической модели взлетают до 129 560; затраты предлагаемой логической модели Overlay стабильно зафиксированы на отметке 2 097 (коэффициент сжатия достигает 61.78×).

Б. Интерпретация основных экспериментальных выводов

Абсолютный иммунитет к расширению физической топологии (свойство $\mathcal{O}(1)$): Как видно из столбца $\mathrm{S_o}(\mathrm{T} = 300)$ Таблицы 1, в то время как затраты традиционной модели $\mathrm{S_u}$ демонстрируют крутой квадратичный взрыв под давлением физических туннелей и распределенных шлюзов Anycast, достигая огромного значения 129 560, затраты предлагаемой логической дедуплицированной модели стабильно фиксируются в узком диапазоне около 2 100 (колеблясь от 2 139 при $\mathrm{N} = 10$ до 2 097 при $\mathrm{N} = 100$). На Рисунке 2(a) эта зависимость отображается в виде абсолютно горизонтальной прямой линии (по правой оси Y). Данный факт строго подтверждает успешное исключение всех членов формулы, содержащих N, обеспечивая песочнице цифрового двойника свойство «иммунитета снижения размерности».

Рост эффективности сжатия при увеличении физического масштаба сети: В полном соответствии с теоретическими выводами третьей главы, по мере роста N избыточные конфигурационные инстансы Anycast-шлюзов на физических коммутаторах накапливаются геометрически. При фиксации масштаба арендаторов на уровне $\mathrm{T} = 300$ коэффициент сжатия ресурсов (CR) демонстрирует линейный рост: от 4.40 раз в сценарии небольшого частного облака $(\mathrm{N} = 10)$ до 61.78 раз в условиях крупномасштабного публичного ЦОД $(\mathrm{N} = 100)$. Это доказывает превосходную масштабируемость (Scalability) алгоритма, эффективность которого возрастает с увеличением масштаба сети, что делает его базисом для верификации IBN в реальном времени.

V. Заключение и перспективы будущих исследований

А. Основные выводы исследования

Для решения проблемы взрывного роста пространства состояний цифровых двойников облачных ЦОД, вызванного распределенной архитектурой Anycast-шлюзов, в настоящей работе предложен метод моделирования легкого Overlay-двойника на основе логической дедупликации инстансов. На основе математической модели вычислительных затрат при эквивалентных ограничениях бизнес-верификации теоретически доказано, что предложенное решение устраняет квадратичные и мультипликативные члены, зависящие от числа физических узлов, снижая сложность пространства состояний с $\mathcal{O}(\mathrm{N}^2 + \mathrm{T} \cdot \mathrm{N})$ до $\mathcal{O}(\mathrm{T})$. Многомерные эксперименты методом Монте-Карло подтвердили наличие у логической модели идеального иммунитета класса $\mathcal{O}(1)$ к расширению физической инфраструктуры. В условиях крупномасштабной сети $(\mathrm{N} = 100, \mathrm{T} = 300)$ метод обеспечил сжатие пространства ресурсов до 61.78 раза, сформировав теоретический и экспериментальный фундамент для практического внедрения легковесных цифровых двойников.

Б. Прикладная ценность для интенционально-управляемых сетей на базе LLM

Конечная ценность предложенной модели заключается в её использовании в качестве высокоскоростной песочницы для упреждающей «проверки безопасности на миллисекундном уровне» перед отправкой конфигураций, сгенерированных большими языковыми моделями. В

будущих интеллектуальных рабочих процессах автоматизированной эксплуатации процедура применения конфигураций будет включать три этапа замкнутого цикла верификации. На первом этапе (трансляция интента) пользователь вводит интент на естественном языке, а LLM преобразует его в конкретные конфигурационные скрипты нижнего уровня. На втором этапе (упреждающая проверка в легковесной песочнице) скрипты передаются в предлагаемый дедуплицированный цифровой двойник Overlay. Благодаря исключению избыточных физических сущностей и туннелей граф топологии подвергается предельному сжатию. Время выполнения алгоритмов проверки маршрутной достижимости (например, обхода графа в глубину DFS) или анализа конфликтов матриц правил ACL сокращается с минут, требуемых традиционной симуляцией, до нескольких миллисекунд. Песочница способна мгновенно определить наличие конфигурационных галлюцинаций LLM и вынести решение о блокировке или пропуске инструкций. На третьем этапе (физическое развертывание) верифицированная логическая конфигурация передается на авторитетный SDN-контроллер, который осуществляет финальное распределенное тиражирование инстансов 1:N на реальные физические коммутаторы Leaf. Данный механизм декупликации логической проверки и физического распределения полностью устраняет разрыв между потребностью больших моделей в секундном отклике и высокой задержкой традиционной симуляции.

B. Перспективы будущих исследований

В дальнейших исследованиях научный коллектив планирует расширить границы возможностей разработанного легковесного базиса цифрового двойника по двум основным направлениям:

Распознавание специфического дрейфа политик: Изучение механизмов инкрементальной синхронизации в реальном времени между логическим цифровым двойником и таблицами SDN-контроллера, а также методов фиксации специфических состояний в условиях, когда из-за внезапных аппаратных сбоев конфигурация на отдельном коммутаторе Leaf отклоняется от глобальных политик арендатора.

Разработка парсеров конфигураций для гетерогенных вендоров NOS: Создание инструментов автоматической трансляции и дедупликации конфигураций для различных сетевых операционных систем (таких как Cisco IOS, Huawei VRP, открытая операционная система SONiC и др.) с их последующим преобразованием в узлы и ребра стандартного логического графа Overlay. Это позволит повысить универсальность и промышленную ценность легковесной платформы цифрового двойника в мультивендорных смешанных сетевых средах.